



INGENIERÍA EN DESARROLLO Y GESTIÓN DE SOFTWARE

EXTRACCIÓN DEL CONOCIMIENTO EN BASES DE DATOS

Actividad Integradora: Predicción del nivel de burnout estudiantil a partir del uso de IA generativa

PRESENTAN:

ARIAS HERNÁNDEZ JOSÉ
BERTADILLO VILLALOBOS LEOBARDO DANIEL
PAREDES DOMÍNGUEZ JASSIEL
AGUILAR GARCÍA ÁNGEL GABRIEL
TORRES GALVÁN ALEJANDRO ALDAHIR

GRUPO: 9º C

Profesora:

VIRNA VIRIDIANA VELA RINCÓN

Emiliano Zapata, Morelos, México.

Resumen

Este trabajo aplica la metodología **KDD** (*Knowledge Discovery in Databases*) sobre un conjunto de datos de **50 000 estudiantes** universitarios que describe sus hábitos de estudio y de uso de inteligencia artificial generativa. El objetivo es construir un modelo supervisado que prediga el **nivel de burnout** (agotamiento) de un estudiante —*Low*, *Medium* o *High*— a partir de esas características, por lo que se trata de un problema de **clasificación de tres clases**. Tras limpiar y transformar los datos, se compararon tres algoritmos vistos en clase: **árbol de decisión**, **K-Vecinos más Cercanos (KNN)** y **Máquinas de Vectores de Soporte (SVM)**. El mejor resultado lo obtuvo el árbol de decisión, con una exactitud de **52.48 %** y un *Macro F1* de **0.5235**, seguido de cerca por SVM (52.12 %) y KNN (50.02 %). El análisis reveló que la variable más determinante, con mucha diferencia, es el **número de horas semanales de uso de IA**, que concentra cerca del 80 % de la importancia del modelo.

Palabras clave: KDD, clasificación multiclase, árbol de decisión, KNN, SVM, burnout estudiantil, IA generativa, matriz de confusión.

Índice

1. Introducción y Marco Teórico	1
1.1. Contexto y objetivo	1
1.2. La metodología KDD	1
1.3. Árbol de decisión	1
1.4. K-Vecinos más Cercanos (KNN)	2
1.5. Máquinas de Vectores de Soporte (SVM)	2
2. Selección y Descripción del Dataset	2
2.1. Origen y objetivo del análisis	2
2.2. Descripción de las variables	3
3. Preparación y Análisis de los Datos	3
3.1. Limpieza (preprocesamiento)	3
3.2. Estadísticas descriptivas	4
3.3. Distribución de la variable objetivo	4
3.4. Análisis exploratorio	5
3.5. Transformación de los datos	6
4. Aplicación de los Modelos	7
4.1. Diseño experimental	7
4.2. Árbol de decisión	7
4.3. K-Vecinos más Cercanos (KNN)	8
4.4. Máquinas de Vectores de Soporte (SVM)	8
5. Resultados y Evaluación	8
5.1. Comparación de desempeño	8
5.2. Análisis de las matrices de confusión	9
5.3. Métricas por clase	10
5.4. Cálculo manual de las métricas	10
6. Conclusiones	11

1. Introducción y Marco Teórico

1.1. Contexto y objetivo

El uso de herramientas de inteligencia artificial generativa (como los asistentes de chat) se ha vuelto parte del día a día de los estudiantes universitarios. Junto con sus beneficios, ha surgido la preocupación por sus efectos en el bienestar y el desempeño académico. En este trabajo se estudia una de esas consecuencias: el **burnout** o agotamiento estudiantil.

El objetivo es responder, con datos, a la pregunta: *¿es posible predecir el nivel de burnout de un estudiante a partir de sus hábitos de estudio y de uso de IA?* Para ello se plantea un problema de **clasificación con tres categorías** (nivel de burnout bajo, medio y alto) y se comparan tres algoritmos de aprendizaje supervisado. Todo el desarrollo se organiza bajo la metodología KDD.

1.2. La metodología KDD

KDD (*Knowledge Discovery in Databases*) es un proceso ordenado para extraer conocimiento útil a partir de datos en bruto. En este trabajo se recorren sus cinco etapas, que dan estructura al resto del documento:

1. **Selección.** Elegir el conjunto de datos y las variables relevantes para el problema (Sección 2).
2. **Preprocesamiento.** Revisar y corregir la calidad de los datos: valores faltantes, duplicados y columnas inútiles (Sección 3).
3. **Transformación.** Adaptar los datos al formato que necesitan los algoritmos: crear variables, codificar categorías y estandarizar (Sección 3).
4. **Minería de datos.** Aplicar los algoritmos de aprendizaje para encontrar patrones (Sección 4).
5. **Interpretación y evaluación.** Medir los resultados y traducirlos en conclusiones (Secciones 5 y 6).

1.3. Árbol de decisión

Un árbol de decisión clasifica haciendo una serie de preguntas encadenadas sobre las variables, como “¿usa más de 12 horas de IA a la semana?”. Cada pregunta divide a los estudiantes en grupos más puros (donde predomina una sola clase), hasta llegar a una hoja que asigna la categoría final. Para decidir qué pregunta hacer en cada paso, el árbol busca la división que más reduce la **impureza**, medida usualmente con el índice de Gini:

$$\text{Gini}(t) = 1 - \sum_{c=1}^C p_c^2, \quad (1)$$

donde p_c es la proporción de ejemplos de la clase c en el nodo t . Su gran ventaja es que es **fácil de interpretar** y no necesita que las variables estén en la misma escala.

Control de la profundidad

Si se deja crecer sin límite, el árbol memoriza los datos de entrenamiento y falla con datos nuevos (sobreajuste). Por eso se controlan su **profundidad máxima** y el **mínimo de ejemplos por hoja**, buscando los valores que mejor generalizan mediante validación cruzada.

1.4. K-Vecinos más Cercanos (KNN)

La idea de KNN es muy sencilla: para clasificar a un estudiante nuevo, busca los k estudiantes más **parecidos** a él dentro de los datos conocidos y le asigna la clase más común entre ellos (votación mayoritaria). El parecido se mide con la **distancia euclidiana**:

$$d(\mathbf{x}, \mathbf{x}') = \sqrt{\sum_{j=1}^p (x_j - x'_j)^2}. \quad (2)$$

Como esta distancia depende del tamaño de los números, KNN es muy sensible a la escala de las variables, por lo que es indispensable **estandarizarlas** antes de aplicarlo.

1.5. Máquinas de Vectores de Soporte (SVM)

SVM busca la mejor frontera que separa a las clases, es decir, la que deja **el mayor margen** posible a ambos lados. Cuando las clases no se pueden separar con una línea recta, usa el **truco del kernel**: transforma los datos a un espacio de más dimensiones donde sí es posible separarlos. Uno de los kernels más usados es el *Radial Basis Function* (RBF):

$$K(\mathbf{x}, \mathbf{x}') = \exp(-\gamma \|\mathbf{x} - \mathbf{x}'\|^2), \quad \gamma > 0. \quad (3)$$

El parámetro C controla cuánto se penalizan los errores y γ qué tan ajustada es la frontera. Al igual que KNN, SVM se basa en distancias y requiere estandarizar las variables.

2. Selección y Descripción del Dataset

2.1. Origen y objetivo del análisis

El conjunto de datos utilizado es **AI Student Impact Dataset**, obtenido de la plataforma **Kaggle**. Simula el efecto del uso de IA generativa sobre el desempeño y el bienestar de estudiantes universitarios. Se eligió por cumplir el requisito de tener **miles de registros** (50 000) y por incluir una variable de clase clara y de interés actual: el nivel de burnout.

El archivo `ai_student_impact_dataset.csv` contiene **50 000 filas** y **16 columnas**. Cada fila representa a un estudiante. La variable objetivo es `Burnout_Risk_Level`, y las 15 restantes son las características con las que se intentará predecirla (una de ellas, `Student_ID`, es solo un identificador y se descarta).

2.2. Descripción de las variables

La Tabla 1 resume las variables del conjunto, su tipo y su significado. Hay una mezcla de variables **numéricas** (promedios, horas, puntajes) y **categorías** (carrera, año, tipo de uso, política institucional).

Tabla 1: Descripción de las variables del conjunto de datos.

Variable	Tipo	Descripción
Student_ID	Entero	Identificador único del estudiante (se elimina).
Major_Category	Categoría	Área de estudio (STEM, Business, Humanities, Medical, Arts).
Year_of_Study	Categoría	Año o nivel (Freshman, Sophomore, Junior, Senior, Graduate).
Pre_Semester_GPA	Numérica	Promedio académico antes del semestre (1–4).
Weekly_GenAI_Hours	Numérica	Horas semanales de uso de IA generativa.
Primary_Use_Case	Categoría	Uso principal que da a la IA (depuración, redacción, ideación, etc.).
Prompt_Engineering_Skill	Categoría	Habilidad para escribir prompts (Beginner, Intermediate, Advanced).
Tool_Diversity	Entero	Número de herramientas de IA distintas que usa (1–5).
Paid_Subscription	Booleana	Si tiene una suscripción de pago a alguna herramienta.
Traditional_Study_Hours	Numérica	Horas semanales de estudio tradicional (sin IA).
Perceived_AI_Dependency	Entero	Dependencia percibida de la IA (escala 1–10).
Institutional_Policy	Categoría	Política de la institución sobre el uso de IA.
Anxiety_Level_During_Exams	Entero	Nivel de ansiedad en exámenes (escala 1–10).
Post_Semester_GPA	Numérica	Promedio académico después del semestre (1–4).
Skill_Retention_Score	Numérica	Puntaje de retención de habilidades (0–100).
Burnout_Risk_Level	Categoría	Variable objetivo: nivel de agotamiento (Low, Medium, High).

3. Preparación y Análisis de los Datos

3.1. Limpieza (preprocesamiento)

La primera revisión de calidad arrojó un conjunto en muy buen estado:

- **Datos faltantes:** 0 valores nulos en todo el conjunto.
- **Duplicados:** 0 filas repetidas.
- **Columnas sin valor predictivo:** se eliminó `Student_ID` por ser solo un identificador.

Al no haber datos faltantes ni duplicados, no fue necesario imputar ni eliminar registros; el conjunto quedó en **50 000** filas y **15** columnas útiles.

3.2. Estadísticas descriptivas

La Tabla 2 muestra las estadísticas de las principales variables numéricas. Destaca que las horas semanales de IA tienen un rango muy amplio (de 0 a 40) y una media de 8.4 horas, mientras que el promedio académico sube ligeramente entre el inicio y el fin del semestre (de 3.15 a 3.35 en promedio).

Tabla 2: Estadísticas descriptivas de variables numéricas seleccionadas.

Variable	Media	Desv.	Mín.	Mediana	Máx.
Pre_Semester_GPA	3.15	0.48	1.18	3.21	4.00
Weekly_GenAI_Hours	8.43	8.27	0.00	5.80	40.00
Traditional_Study_Hours	11.21	5.16	1.00	11.18	35.86
Perceived_AI_Dependency	3.51	1.82	1.00	3.00	10.00
Anxiety_Level (exámenes)	4.27	2.14	1.00	4.00	10.00
Post_Semester_GPA	3.35	0.50	1.00	3.42	4.00
Skill_Retention_Score	75.80	13.28	10.78	76.00	100.00

3.3. Distribución de la variable objetivo

La Tabla 3 y la Figura 1 muestran cómo se reparten las tres clases. La clase *Medium* es la más frecuente (42.29 %) y *High* la menos común (24.97 %). No es un desbalance grave, pero por precaución la evaluación se apoya también en el *Macro* F1, que da el mismo peso a las tres clases y no solo a la más numerosa.

Tabla 3: Distribución de instancias por nivel de burnout.

Clase	Instancias	Proporción
Low	16 369	32.74 %
Medium	21 144	42.29 %
High	12 487	24.97 %
Total	50 000	100 %




Figura 1: Distribución de estudiantes por nivel de burnout.


3.4. Análisis exploratorio

Para entender qué variables se relacionan con el burnout, la Tabla 4 compara el promedio de algunas variables entre las tres clases. El patrón más claro es el de las **horas de IA**: pasan de 4.6 horas semanales en los estudiantes con burnout bajo a **15.2 horas** en los de burnout alto, más del triple. También sube la dependencia percibida de la IA y, ligeramente, la ansiedad.


Tabla 4: Promedio de variables clave según el nivel de burnout.

Variable (promedio)	Low	Medium	High
Weekly_GenAI_Hours	4.64	7.35	15.21
Traditional_Study_Hours	11.97	11.29	10.08
Perceived_AI_Dependency	2.82	3.36	4.64
Anxiety_Level (exámenes)	3.93	4.17	4.89
Skill_Retention_Score	76.40	76.24	74.25

La Figura 2(a) confirma visualmente esta relación: a mayor nivel de burnout, mayor es la mediana y la dispersión de las horas de IA. Por su parte, la Figura 2(b) muestra las correlaciones entre variables numéricas, donde destaca la fuerte relación entre el promedio antes y después del semestre.



(a) Horas de IA por nivel de burnout



(b) Correlación entre variables numéricas

Figura 2: Análisis exploratorio de las variables numéricas.

3.5. Transformación de los datos

Antes de entrenar los modelos se aplicaron tres transformaciones:

1. **Variable derivada.** Se creó $\text{GPA_Change} = \text{Post_Semester_GPA} - \text{Pre_Semester_GPA}$, que resume si el estudiante mejoró o empeoró su promedio durante el semestre.
2. **Codificación de categóricas.** Las variables de texto se convirtieron a numéricas mediante *one-hot encoding* (una columna binaria por categoría). Tras este paso, el conjunto pasó a tener **26 variables predictoras**.
3. **División y estandarización.** Los datos se separaron en **80 % para entrenar** (40 000 ejemplos) y **20 % para probar** (10 000), de forma **estratificada** para conservar la proporción de clases. La estandarización se ajustó **solo con los datos de entrenamiento** y luego se aplicó a los de prueba, para no filtrar información.

¿Por qué estandarizar?

KNN y SVM se basan en distancias, así que una variable con números grandes (como el puntaje de retención, de 0 a 100) pesaría más que otra pequeña (como la diversidad de herramientas, de 1 a 5) sin ninguna razón. La estandarización deja a todas en una escala comparable. El árbol de decisión no lo necesita, porque trabaja con umbrales sobre cada variable por separado.

4. Aplicación de los Modelos

4.1. Diseño experimental

El experimento se implementó en Python con la biblioteca `scikit-learn`. Los tres modelos se entrenaron sobre los mismos datos de entrenamiento y se evaluaron sobre el mismo conjunto de prueba de 10 000 ejemplos, para que la comparación fuera justa. Para cada modelo se buscaron sus mejores parámetros con **validación cruzada de 5 particiones**.

SVM sobre una muestra representativa

Entrenar SVM con kernel RBF sobre las 40 000 filas de entrenamiento es muy costoso: un solo entrenamiento tarda varios minutos y una búsqueda de parámetros tardaría horas. Por eso, y como se acordó, el SVM se ajustó y entrenó sobre una **muestra estratificada de 10 000 ejemplos** del conjunto de entrenamiento. La evaluación se hizo sobre el mismo conjunto de prueba que los otros dos modelos.

4.2. Árbol de decisión

Se probaron distintas profundidades y tamaños mínimos de hoja. La mejor configuración fue **profundidad máxima 6** y **mínimo 50 ejemplos por hoja**. La Figura 3 muestra qué variables usa más el árbol para decidir: `Weekly_GenAI_Hours` domina de forma aplastante, con cerca del **80 %** de la importancia total, muy por encima del resto.




Figura 3: Importancia de las variables en el árbol de decisión.

4.3. K-Vecinos más Cercanos (KNN)

Se evaluaron varios valores de k mediante validación cruzada (Figura 4). La exactitud crece al aumentar k y se estabiliza alrededor de $k = 101$, valor que se eligió como el mejor. Que se necesite un k tan grande es una señal de que las clases están muy mezcladas: el modelo necesita observar a muchos vecinos para decidir con cierta estabilidad.




Figura 4: Exactitud media por validación cruzada en función de k .

4.4. Máquinas de Vectores de Soporte (SVM)

La búsqueda en rejilla sobre la muestra de 10 000 ejemplos seleccionó un **kernel RBF** con $C = 1$ y $\gamma = \text{scale}$. Esta configuración ofreció el mejor equilibrio entre ajuste y capacidad de generalización.

5. Resultados y Evaluación

5.1. Comparación de desempeño

La Tabla 5 y la Figura 5 resumen el desempeño de los tres modelos sobre el conjunto de prueba. El **árbol de decisión** obtuvo el mejor resultado (52.48 % de exactitud), seguido muy de cerca por SVM (52.12 %) y KNN (50.02 %). Las diferencias son pequeñas, lo que indica que ningún algoritmo logra una ventaja clara sobre este problema.

Tabla 5: Comparación de los tres modelos sobre el conjunto de prueba (10 000 instancias).

Modelo	Accuracy	Macro F1	T. entren. (s)*	T. predic. (s)*
Árbol de decisión	0.5248	0.5235	0.28	< 0.01
SVM (RBF)	0.5212	0.5127	10.16	8.97
KNN ($k = 101$)	0.5002	0.4770	0.07	6.10

*Los tiempos son aproximados y dependen del equipo; interesa su comparación relativa, no el valor absoluto.




Figura 5: Comparación de exactitud y *Macro* F1 de los tres modelos.

Sobre los tiempos, el árbol es el más práctico: entrena y predice casi al instante. KNN casi no tarda en entrenar (solo guarda los datos), pero es lento al predecir porque debe comparar cada caso con todos los ejemplos. SVM es el más costoso de entrenar, razón por la que se trabajó con una muestra.

Sobre el nivel de exactitud

Un 52 % de aciertos puede parecer bajo, pero conviene ponerlo en contexto: al haber **tres clases**, adivinar al azar acertaría solo alrededor del 33 %. Los modelos superan claramente ese punto de partida. Aun así, el techo cercano al 52 % —que se repitió con los tres algoritmos— indica que el burnout **solo puede predecirse de forma parcial** con estas variables: buena parte del fenómeno depende de factores personales que el conjunto de datos no captura.

5.2. Análisis de las matrices de confusión

Las Figuras 6(a), 6(b) y 6(c) muestran las matrices de confusión de los tres modelos. En todas se repite el mismo patrón: la clase *Medium*, al estar “en medio”, comparte características con las otras dos y es donde se concentra la mayor confusión. La clase *High* es la que mejor se identifica cuando se predice (alta precisión), aunque muchos de sus casos se escapan hacia *Medium* (baja sensibilidad).




Figura 6: Matrices de confusión de los tres modelos sobre el conjunto de prueba.

5.3. Métricas por clase

La Tabla 6 desglosa el F1 por clase para cada modelo. Se aprecia que la clase *Medium* es donde el árbol y el SVM se apoyan más, mientras que KNN, con su k grande, tiende a predecir *Medium* en exceso y por eso baja su desempeño en *High*.

Tabla 6: F1-Score por clase para cada modelo.

Modelo	Low	Medium	High
Árbol de decisión	0.5249	0.5277	0.5179
SVM (RBF)	0.4907	0.5488	0.4987
KNN ($k = 101$)	0.4524	0.5522	0.4263

5.4. Cálculo manual de las métricas

Al igual que en las actividades anteriores, las métricas se comprobaron **a mano** a partir de la matriz de confusión, bajo el esquema *una clase contra el resto*. Para cada clase se definen cuatro cantidades — verdaderos positivos (TP), falsos negativos (FN), falsos positivos (FP) y verdaderos negativos (TN)— y se aplican las fórmulas vistas en clase:

$$\text{Precisión} = \frac{TP}{TP + FP}, \quad \text{Sensibilidad} = \frac{TP}{TP + FN}, \quad \text{Especificidad} = \frac{TN}{TN + FP}. \quad (4)$$

A modo de ejemplo, se desarrolla el cálculo para la clase **High** del mejor modelo (el árbol de decisión). De su matriz de confusión se obtiene $TP = 1042$, $FN = 1455$, $FP = 485$ y $TN = 7018$:

$$\begin{aligned} \text{Precisión} &= \frac{1042}{1042 + 485} = 0.6824, & \text{Sensibilidad} &= \frac{1042}{1042 + 1455} = 0.4173, \\ \text{Especificidad} &= \frac{7018}{7018 + 485} = 0.9354. \end{aligned}$$

Aplicando el mismo procedimiento a las tres clases se obtiene la Tabla 7. La exactitud global se calcula como el total de aciertos (la diagonal de la matriz) entre el total de instancias: $\frac{1745+2461+1042}{10\,000} = \frac{5248}{10\,000} = 0.5248$, que coincide con el valor entregado por la implementación y confirma la consistencia de los resultados.

Tabla 7: Cálculo manual de métricas por clase para el árbol de decisión (esquema una contra el resto).

Clase	TP	FN	FP	TN	Precisión	Sensibilidad	Especificidad
Low	1745	1529	1630	5096	0.5170	0.5330	0.7577
Medium	2461	1768	2637	3134	0.4827	0.5819	0.5431
High	1042	1455	485	7018	0.6824	0.4173	0.9354

6. Conclusiones

Siguiendo la metodología KDD, se logró construir y evaluar un modelo supervisado capaz de predecir el nivel de burnout estudiantil a partir de hábitos de estudio y de uso de IA. Las principales conclusiones son:

- El **árbol de decisión** ofreció el mejor equilibrio entre desempeño, rapidez e interpretabilidad, con una exactitud de **52.48 %** y un *Macro F1* de **0.5235**, apenas por encima de SVM y KNN.
- El hallazgo más importante del análisis no es tanto el modelo ganador como **qué variable manda**: el **número de horas semanales de uso de IA** concentra cerca del 80 % de la importancia. Los estudiantes que usan la IA de forma más intensiva tienden a reportar un burnout más alto.
- La exactitud, cercana al 52 % frente al 33 % del azar, muestra que el burnout es **parcialmente predecible**: estas variables explican una parte del fenómeno, pero no todo. Esto es esperable, ya que el agotamiento también depende de factores personales y de contexto que el conjunto de datos no recoge.
- La clase *Medium* es la más difícil de separar por estar “en medio” de las otras dos, y es donde se concentra la mayor parte de los errores de los tres modelos.

En conjunto, el trabajo cumple el objetivo planteado: más allá del porcentaje de aciertos, el mensaje práctico es que el **uso intensivo de IA generativa es el factor más asociado al agotamiento** de los estudiantes, un resultado que invita a promover un uso más equilibrado de estas herramientas.